

Stress e Stile di Vita: Come le Abitudini degli Studenti Influenzano il loro Benessere Mentale

Questa analisi si propone di rispondere a diversi interrogativi che riguardano la relazione tra le abitudini quotidiane degli studenti e il loro stato psicologico e mentale. In particolare, si intende esplorare come gli aspetti della vita di tutti i giorni influenzino il livello di stress, contribuendo a una comprensione più profonda del benessere degli studenti.

Il dataset utilizzato per l'analisi, denominato "Student Lifestyle"¹, offre una visione approfondita delle abitudini quotidiane degli studenti e sui livelli di stress in relazione anche ai loro risultati accademici prendendo in considerazione un campione casuale di 2000 studenti universitari.

Le variabili analizzate sono le seguenti:

- Ore dedicate allo studio: un elevato numero di ore di studio potrebbe portare a risultati accademici migliori, ma anche ad aumentare i livelli di stress, se non bilanciato con altre attività.
- Durata del sonno: il riposo è essenziale per la memoria e la concentrazione. Una mancanza di sonno è spesso associata ad alti livelli di stress e a difficoltà nell'apprendimento.
- Attività fisica: un regolare esercizio aiuta a ridurre lo stress e migliorare la salute mentale, in quanto stimola la produzione di endorfine e aumenta il benessere generale.
- Ore dedicate ad attività sociali: le interazioni con amici e familiari spesso fungono da valvole di sfogo per la tensione accumulata durante le ore studio e negli impegni accademici.
- Attività extracurricolari: partecipare ad attività extracurricolari può aiutare gli studenti a gestire meglio il carico di lavoro, anche se un coinvolgimento elevato potrebbe generare stress aggiuntivo.
- GPA (Grade Point Average)²: il rendimento accademico e lo stress sono fortemente connessi: la pressione di raggiungere un GPA più alto contribuisce ad aumentare l'ansia.

Variabile di riferimento: Livello di Stress

Esso è suddiviso in tre modalità, basate sui valori emersi dall'indagine, ponderando ogni risposta in relazione al suo impatto positivo o negativo sulla salute psicologica:

- Low (basso)
- Moderate (moderato)
- High (alto)




Figura 1- Distribuzione di frequenze assolute dei livelli di stress

Come si può notare in Fig. 1 livello di stress "High" è il più comune, con oltre 1000 osservazioni, seguito dal livello "Moderate", che è meno frequente ma comunque significativo. Il livello "Low" è il meno rappresentato, con meno di 300 osservazioni, mostrando una popolazione tendenzialmente più esposta allo stress.

¹ <https://www.kaggle.com/datasets/steve1215rogg/student-lifestyle-dataset/data>

² Viene calcolato su una scala che va generalmente da 0 a 4.0, che corrisponde al massimo rendimento accademico. Il GPA è un indicatore fondamentale per ammissioni universitarie, borse di studio e opportunità di lavoro.

Quali sono i fattori che incidono maggiormente sul livello di stress degli studenti?




Figura 2 - Distribuzione della varianza spiegata dalle variabili in presenza di outlier.

Dall'analisi della PCA (Principal Component Analysis) emerge che le prime quattro componenti principali sono le più rilevanti per spiegare la varianza dei dati (Fig. 2), con un valore spiegato pari all'82% del totale della varianza.

Poiché la PCA mira a ridurre la dimensionalità mantenendo la maggior parte dell'informazione, il dataset verrà analizzato attraverso le variabili più influenti, ovvero: “Study_Hours”, “Physical_Activity_Hours”, “Social_Hours” ed “Extracurricular_Hours”. Secondo i risultati dell'analisi preliminare svolta, queste variabili potrebbero contenere informazioni rilevanti per il clustering. In particolare, osserviamo che le Ore di Studio (“Study_Hours”) e quelle di attività fisica (“Physical_Activity_Hours”), sono le variabili che spiegano la maggior parte della varianza. Un'interessante analisi può essere quella che verifica l'entità del rapporto che queste due hanno rispetto ai livelli di stress.




Figura 3 - Boxplot per la distribuzione delle classi rispetto alle variabili

L'analisi dei dati mostrata in Fig. 3 mostra un legame tra le ore dedicate allo studio e i livelli di stress: gli studenti che studiano di più tendono a sperimentare un maggiore stress, mentre chi dedica meno tempo allo studio presenta livelli di stress più bassi. Contrariamente, le ore di attività fisica risultano come fattore che riduce lo stress: gli studenti meno stressati generalmente dedicano un ammontare di tempo maggiore all'esercizio fisico.

Dal grafico sembrerebbe emergere la presenza di outliers³ nella categoria “High” per queste due variabili. Procediamo con un'analisi della distribuzione dei livelli di stress tramite un grafico a dispersione delle due variabili (Fig.4), per una visualizzazione più chiara della disposizione dei punti nelle diverse categorie.




Figura 4 - Prima




Figura 5 - Dopo

Il risultato suggerisce che alcune osservazioni del livello “High” siano state erroneamente collocate in questa categoria in quanto assumono valori che sembrerebbero essere associabili al livello di stress “Low”. Per migliorare la qualità della classificazione, le osservazioni mal attribuite sono state identificate e gestite tramite il criterio dell'Interquartile Range (IQR). In particolare, 79 unità statistiche sono state rimosse dal dataset per evitare distorsioni nell'analisi, come è possibile notare in Fig. 5.

³ Gli “outliers” sono valori anomali che si discostano significativamente dai dati. Essi possono derivare da errori nel campionamento, variazioni naturali o eventi rari.

Come varia l'analisi del dataset al netto degli outliers?




Figura 6 – Distribuzione della varianza spiegata dalle variabili in presenza di outlier.

Poiché la PCA (Principal Component Analysis) è particolarmente sensibile ai valori estremi, è fondamentale assicurarsi che il dataset sia privo di outliers che potrebbero distorcere i risultati. Per questo motivo, dopo aver eliminato le osservazioni anomale, ripetiamo l'analisi. Questo permetterà di ottenere le componenti principali più rappresentative al netto degli outliers.

Dall'analisi condotta (Fig. 6) emerge che, dopo la rimozione degli outliers, le variabili che spiegano la maggior parte della varianza (in particolare il 79% che è un valore accettabile dal momento che supera il 60%, generalmente preso come standard) del dataset sono “Study_Hours”, “Sleep_Hours”, “Extracurricular_Hours” e “Physical_Hours”.

L'aggiornamento dell'analisi (Fig. 7) permette di ottenere una rappresentazione più chiara della variabilità tra le classi di stress. La variabile che mostra la maggiore dispersione tra i tre livelli di stress rimangono le ore di studio, mentre quella che presenta meno variazioni rispetto alle categorie considerate è quella legata alle attività extracurricolari. Al contrario, le ore dedicate all'attività fisica e quelle di sonno mostrano una riduzione al crescere del livello di stress, evidenziando un possibile legame tra un carico maggiore e una diminuzione del tempo riservato al riposo e all'esercizio fisico.

La pulizia del dataset ha reso questi effetti più evidenti, riducendo la distorsione introdotta dai valori anomali e migliorando l'affidabilità dell'analisi.




Figura 7 - Boxplot

E tra loro come si influenzano? Come sono correlate?




Figura 8 - Mappa di calore (Heatmap) raffigurante le correlazioni

La matrice di correlazione mostra che ore di studio, ore impiegate per attività extracurricolari e fisiche e ore di sonno sono poco correlate tra loro, indicando che ciascuna veicola informazioni diverse dello stile di vita degli studenti.

Le correlazioni più forti evidenziano come il tempo dedicato a una certa attività influenzi la riduzione di altre. Ad esempio, la correlazione negativa tra ore di studio e attività fisica (-0.452) suggerisce che chi studia di più tende a fare meno esercizio. Allo stesso modo, la correlazione negativa tra attività fisica e ore di sonno (-0.432) indica che chi è più attivo fisicamente potrebbe dormire meno. Questo riflette scelte di priorità: dedicare più tempo a un'attività spesso significa sacrificare altre.

Tuttavia, nessuna variabile è fortemente dipendente dalle altre, suggerendo che ogni variabile misura una caratteristica indipendente del comportamento degli studenti, rendendole utili per un'analisi più ampia senza rischio di ridondanza nei dati.

Il clustering statistico può davvero sostituire una classificazione basata su studi psicologici?




Figura 9 - Confronto tra la divisione in gruppi fornita dal dataset e quella proposta con un approccio Model-Based

Il confronto tra la classificazione originale del livello di stress e quella ottenuta tramite il metodo di clustering Mclust (Fig. 9) evidenzia differenze significative. La classificazione iniziale, basata su studi psicologici, suddivide chiaramente gli studenti in tre gruppi: alto stress (molte ore di studio e poca attività fisica), basso stress (meno studio e più attività fisica) e moderato stress (condizione intermedia).

Il clustering Mcclust, invece, ignora le etichette iniziali e suddivide i dati solo in base a schemi statistici, risultando in una segmentazione diversa, soprattutto per il gruppo a basso stress. Il risultato della clusterizzazione dei dati è più omogeneo: le numerosità dei tre gruppi sono 637, 625, 659 contro i raggruppamenti iniziali di 297, 647, 950. Sebbene il clustering possa rivelare strutture nei dati, non sempre queste corrispondono a una reale differenza psicologica tra gli studenti.

In conclusione, la classificazione originale, basata su studi scientifici, considera aspetti qualitativi dello stress che un'analisi puramente statistica potrebbe non catturare.

Sebbene i metodi di clustering possano fornire spunti interessanti, non dovrebbero sostituire modelli consolidati derivati dalla ricerca psicologica.




Figura 10 - Matrice di confronto tra la classificazione originale e quella proposta da MClust

Il modello ha difficoltà a distinguere la classe “Moderate”, con molte osservazioni erroneamente assegnate a “Low” o “High”, indicando una sovrapposizione tra le categorie e una separazione non chiara nei dati (valore accuracy: 50.6%).

Possiamo predire il livello di stress di uno studente basandoci sulle sue abitudini?




Figura 11 – Rappresentazione delle funzioni discriminanti quadratiche che dividono i 3 gruppi del modello

Il dataset viene suddiviso in due insiemi per valutare l'accuratezza del modello (l'80% viene utilizzato per l'addestramento e il 20% per il test). All'interno della classificazione vengono testati diversi modelli gaussiani, valutandoli attraverso due criteri statistici: il Misclassification Error Rate (MER) con la tecnica di Cross-Validation e il Bayesian Information Criterion (BIC), un indice che penalizza i modelli per la loro complessità (sia per il numero di parametri che per la numerosità campionaria) con lo scopo di ridurre il rischio di overfitting⁴. Tra le varie configurazioni provate, il modello migliore risulta essere Gaussian_p_Lk_Ck (Fig. 11) con un CV di 0.082 e un BIC di 22507.93 (Fig. 12).



Figura 12 - Visualizzazione grafica della scelta di BIC ed ICL ottimali

⁴ L'overfitting avviene in modelli troppo complessi che si adattano eccessivamente ai dati di training, includendo anche il rumore.

Dopo aver selezionato il modello migliore, viene effettuata la predizione sui dati di test, ossia su dati non usati in fase di addestramento, per verificare la capacità del modello di classificare correttamente nuove osservazioni.

Per valutare l'affidabilità delle previsioni, mostriamo il risultato della matrice di confusione, ottenuto attraverso il metodo di classificazione “mixtmodLearn” di R che confronta le classi reali con quelle predette (Fig.13).

Confusion Matrix

	1	2	3
1	51	0	0
2	0	120	20
3	0	15	179

Predizione

Figura 13 - Matrice di confronto tra la classificazione originale e quella proposta da mixtmodLearn

La matrice di confusione mostra un'ottima classificazione della prima classe, mentre la seconda e la terza presentano una lieve sovrapposizione, con alcune osservazioni assegnate erroneamente tra loro. Il modello raggiunge un'accuratezza del 90.91%.

Stress e rendimento accademico: analisi con regressione e clustering

Heatmap di Correlazione Generale




Figura 14 - Mappa di calore (Heatmap) raffigurante le correlazioni

L'analisi esplora il legame tra stress e rendimento accademico (*GPA*) attraverso un modello di regressione con clustering misto, valutando il livello di stress sia come predittore diretto che come variabile di clustering. Da una visualizzazione grafica della correlazione tra le variabili (Fig. 14) emerge che il *GPA* ha una forte correlazione positiva (+0.726) con le ore di studio, suggerendo che un maggiore impegno nello studio è legato a un miglior rendimento accademico. D'altra parte, il *GPA* mostra una correlazione negativa più moderata con

le ore di attività fisica (-0.308), indicando che un aumento del tempo dedicato allo sport potrebbe influenzare negativamente le performance accademiche. Le altre variabili presentano correlazioni molto deboli, suggerendo che il loro impatto sul *GPA* è trascurabile.

Complessivamente, questi risultati confermano che le ore di studio rappresentano il fattore più determinante nella variazione del rendimento accademico.




Figura 15 - Andamento degli indici dopo aver verificato la convergenza

Per la segmentazione degli studenti, l'analisi (Fig. 15) ha evidenziato che il modello con due cluster ($ICL = 5669.152$) è più stabile rispetto a quello con tre, il quale, pur mostrando un ICL inferiore ($ICL = 5191.451$), non raggiunge convergenza e risulta quindi meno affidabile. La suddivisione ottimale distingue due gruppi con caratteristiche ben definite: il Cluster 1, composto principalmente da studenti con stress moderato o basso, e il Cluster 2, dominato da individui con stress elevato.

Il livello di stress varia tra i cluster? Che ruolo assume ai fini classificativi?

Distribuzione dei livelli di stress nei cluster




Figura 16 - Distribuzione dei livelli di stress nei cluster

Osservando la distribuzione dei livelli di stress nei cluster (Fig. 16), emerge che il Cluster 1 raccoglie prevalentemente studenti con livelli di stress più

contenuti, mentre il Cluster 2 include una quota significativa di studenti con stress alto. Questo suggerisce che il modello ha utilizzato efficacemente il livello di stress come criterio distintivo, segmentando gli studenti tramite la loro gestione della pressione accademica.

Le ore di studio e lo sport influenzano il rendimento accademico nei cluster?




Figura 17 - Relazione tra GPA e ore di studio per cluster

L'analisi delle relazioni tra GPA e le ore di attività fisica (Fig. 18) e di studio (Fig. 17) conferma le tendenze individuate nella correlazione: l'aumento delle ore di studio è associato a un miglioramento del GPA in entrambi i cluster, sebbene gli studenti del Cluster 1 ottengano in media risultati migliori a parità di ore di studio. Viceversa, un aumento delle ore di sport è generalmente correlato a una lieve diminuzione del GPA, con un impatto più marcato per gli studenti del Cluster 1 rispetto a quelli del Cluster 2, che sembrano meno influenzati da questa variabile.




Figura 18 - Relazione tra GPA e ore di attività fisica per cluster

La media è influenzata dal livello di stress?




Figura 19 - Effetto dello Stress sul GPA Predetto nei Cluster

L'effetto dello stress sul GPA, illustrato attraverso i boxplot (Fig. 19), mostra differenze significative tra i due cluster. Nel Cluster 1, il rendimento accademico risulta essere relativamente stabile indipendentemente dal livello di stress, con una leggera tendenza al ribasso per gli studenti con stress elevato. Nel Cluster 2, invece, il GPA risulta più sensibile alle variazioni di stress: gli studenti con stress moderato ottengono in media le performance migliori, mentre quelli con stress basso registrano il GPA più basso.

Come applicare questi risultati per migliorare il supporto agli studenti?

L'uso combinato dello stress come predittore nella regressione e come variabile di clustering ha permesso di cogliere entrambe le dimensioni di questo fenomeno: da un lato, il suo effetto diretto sulle performance accademiche e, dall'altro, la sua capacità di distinguere gruppi di studenti con dinamiche differenti. Questo suggerisce che lo stress non agisce in modo uniforme su tutti gli studenti, ma impatta in base alla capacità del singolo di gestirlo.

I risultati suggeriscono implicazioni pratiche, indicando che strategie educative ad hoc potrebbero aiutare gli studenti più sensibili allo stress a ottimizzare il loro rendimento. Il Cluster 2, in particolare, sembra includere studenti il cui GPA è più vulnerabile alle fluttuazioni dello stress, indicando che per alcuni una certa dose di pressione potrebbe essere necessaria per mantenere alte performance, mentre per altri potrebbe essere un fattore di rischio. Questo evidenzia la necessità di interventi mirati per supportare gli studenti in base alla loro reattività allo stress, piuttosto che un approccio generalizzato.